

复杂文档处理 Data Agent

基于 MinerU 的可规划、可降级、可追溯文档智能体

智能进化 · Agent 能力评测赛道



多格式输入



Agent 规划



MinerU 解析



结构化抽取



质量校验



可追溯日志

真实文档处理的难点，不止是“读懂文字”

多元输入格式

 PDF 报告：布局复杂，包含大量图表

 Word 合同：条款众多，结构化难度高

 PPT 汇报材料：信息碎片化，非线性排列

 HTML / 网页公告：动态内容，含有大量噪声

核心处理难点

 结构不统一：跨格式信息难以映射到统一模型

 长文档遗漏：跨页信息与长文本容易发生截断

 证据缺失：结果不可追溯，难以进行人工审计

 恢复机制弱：外部解析服务异常时缺乏自动降级

目标：把“解析能力”组织成可复现、可审计、可扩展的数据处理 Agent

系统将复杂任务拆成五个可验证阶段




任务创建: `POST /v1/tasks`

结果查询: `GET /v1/tasks/{id}`

日志审计: `GET /v1/tasks/{id}/logs`

统一中间表示，让解析后端与抽取逻辑解耦



MinerU 三种后端兼顾精度、稳定性与可复现性

后端类型	定位	使用场景
<code>mineru_precise</code>	MinerU SaaS 精准解析	正式评测与高质量解析需求，提供最强布局还原能力
<code>mineru_agent</code>	轻量解析接口	精准接口异常或未配置 Token 时自动降级，保证业务连续性
<code>mineru_local</code>	开源本地 CLI	离线验证与开源工具链复现，支持输出多种中间态 JSON

自动降级与切换策略

★ 优先使用 Precise → 🛡️ 异常自动切换 Agent → 🛠️ 必要时手动切换 Local

* 本地 CLI 已验证可输出 Markdown、Content List、Middle/Model JSON、Layout/Span PDF

结果不仅可读，还能被验证和追溯

</> 多维结构化输出

```
{  
  "summary": "...",  
  "metadata": {...},  
  "entities": [...],  
  "tables": [...],  
  "quality": {...},  
  "evidence": [...]  
}
```

三 全链路审计日志

- ☐ **task_queued**
任务进入队列，分配唯一 ID
- ☐ **plan_created**
Agent 生成 3-6 步执行计划
- ☐ **tool_call**
调用 MinerU 解析后端
- ☐ **task_succeeded**
结构化抽取完成，日志归档

输入、计划、工具、证据、质量检查 均可实时查询

9 个测试样例覆盖多格式输入与 132 页长文档

本地格式验证

输入类型	样例数	执行状态
TXT 纯文本	1	SUCCEEDED
HTML 网页	1	SUCCEEDED
DOCX 文档	1	SUCCEEDED
PPTX 演示	1	SUCCEEDED
PDF 扫描/电子	1	SUCCEEDED

公开 PDF 压力测试

测试文档	页数	解析字符数
arXiv scikit-learn 论文	6	15,351
NASA 空气质量报告	21	138,325
NASA 微电网论文	22	130,522
DigitalOcean 年报	132	510,976

* 所有测试均在当前版本系统上完成，验证了系统对长文档处理的稳定性与 MinerU 解析的准确性。

三步完成一次可追溯的数据处理任务

01 创建任务

POST /v1/tasks

上传本地文件、提交网页 URL 或直接发送待处理文本。系统立即返回唯一 Task ID。

02 查询结果

GET /v1/tasks/{id}

实时查看任务状态、执行计划、工具调用详情以及最终生成的结构化 JSON 结果。

03 查询日志

GET /v1/tasks/{id}/logs

获取完整的事件链记录，包括规划细节、工具输出及任何自动触发的异常恢复操作。

■ ■ ■ TERMINAL - DEMO ENVIRONMENT

```
$ python -m uvicorn src.main:app --host 127.0.0.1 --port 8000
```

```
$ python scripts/run_smoke_tests.py --no-start
```


稳定性来自明确的降级、校验与存储边界



输入保护

- 严格限制上传文件大小
- 多格式 MIME 类型校验
- 输入源合法性预检查



异常恢复

- 精准解析失败自动降级
- API 调用超时重试机制
- Agent 规划冲突自愈



稳定输出

- Pydantic Schema 强校验
- LLM 不可用时 Fallback
- 统一结构化 JSON 格式



可追溯存储

- JSON 任务状态持久化
- JSONL 全量事件日志
- 解析中间态数据留存

NEXT STEPS

强化 OCR 能力 · 引入任务队列 · 补充自动化指标评测 (准确率/召回率)

从“解析文档”走向“可交付的数据处理 Agent”

统一入口

兼容文件上传、网页 URL 及直接文本输入，屏蔽底层来源差异。

可切换工具链

灵活调度 MinerU Precise / Agent / Local 后端，兼顾精度与稳定性。

稳定结构化输出

基于 Pydantic 校验的 JSON 输出，包含摘要、实体、表格及原文证据。

全链路可追溯

详尽的 JSONL 事件日志记录，为生产环境提供必要的审计与调试支持。

 GitHub: github.com/PingGuoMiaoMiao/MinerU_TrackTwo

评审常见问题 (Q&A)

❓ 是否只能解析 PDF 格式？

不是。系统支持 PDF、Word、PPT、HTML、TXT、网页 URL 以及直接文本输入，实现了多源异构数据的统一接入。

❓ 如果 MinerU SaaS 接口不可用怎么办？

系统内置自动降级机制。当精准解析接口异常时，会自动切换至轻量级 Agent 接口，或手动切换至本地开源 CLI 模式。

❓ 抽取结果的准确性如何验证？

结构化结果中包含 evidence 字段，关联原文证据片段。同时，日志接口保留了完整的执行计划、工具调用详情及质量检查记录。

❓ 当前版本还可以从哪些方面进行增强？

后续计划强化极端场景下的 OCR 能力，引入分布式任务队列支持高并发，并补充字段准确率与证据召回率的自动化评测指标。